out. 7, 2026

Rocket Lab 26.2 | Aula 6 - Gold Layer, Views e Orquestração (Prática)

Resumo

Sessão abordou diretrizes de inteligência artificial com arquitetura medalhão e modelagem de dados.

Uso de Inteligência Artificial
Uso de inteligência artificial é incentivado para ganho de eficiência com análise crítica. Decisão confirmou que o uso de mecanismos de mock na API do Databricks será aceito.

Modelagem Camada Gold
Arquitetura medalhão detalhou camadas Bronze, Silver e Gold. Modelagem analítica definiu dimensões, fatos, grão e esquema estrela.

Views e Orquestração Databricks
Tipos de views no Databricks otimizam custos de consultas analíticas. Pipelines e jobs automatizam a execução de fluxos de dados.

Detalhes

Diretrizes sobre o uso de Inteligência Artificial nas atividades: Luigi Rangel levantou uma dúvida sobre a recomendação do uso de inteligência artificial na última atividade do curso. Rafael Tomaz esclareceu que o uso é permitido e incentivado para ganhar eficiência, mas ressaltou que a pessoa desenvolvedora não deve confiar cegamente nas respostas nem praticar programação sem critérios ("vibe coding"). Rafael enfatizou que é fundamental compreender

criticamente as sugestões da IA, entender conceitos teóricos e saber julgar a qualidade do código gerado para garantir segurança e valor de entrega. Luigi compartilhou que evitou o uso excessivo, recorrendo à IA apenas para compreender erros complexos e buscando alternativas em fóruns como StackOverflow, Reddit e Medium.

Boas práticas e otimização com Inteligência Artificial: Rafael Tomaz destacou que a habilidade de realizar buscas eficientes e avaliar criticamente os resultados continua sendo essencial, visto que os modelos probabilísticos exigem julgamento humano. Guilherme Maciel complementou sugerindo uma estratégia avançada de aprendizado: utilizar a IA para criticar o próprio código já funcional, solicitando melhorias de desempenho e explicações sobre as soluções propostas, o que auxilia no desenvolvimento técnico e no avanço da senioridade da pessoa programadora.

Problemas de conexão na API do Databricks e flexibilização das avaliações: Rafael Tomaz comentou sobre problemas reportados nos grupos de São Paulo, Rio de Janeiro e Recife relacionados a falhas e instabilidade ao acessar a API do Databricks. Rafael explicou que contas universitárias ou cadastros realizados fora do ambiente específico de estudos ("free edition") configuram o ambiente de maneira diferente, gerando barreiras de acesso. Para contornar isso, várias pessoas desenvolveram soluções alternativas, como mecanismos de "mock" que tentam acessar a API e recorrem a dados salvos em caso de falha. Rafael garantiu que o uso de "mocks" ou mecanismos similares será plenamente considerado na avaliação e não invalidará a atividade.

Apresentação pessoal e introdução à transformação da camada Gold: Guilherme Maciel apresentou-se como engenheiro de dados na Viságio, formado em Ciência da Computação pela Universidade Federal de Pernambuco (UFPE) e natural de Caruaru. Em seguida, Guilherme introduziu o tema da aula prática focada na camada Gold da arquitetura medalhão, cujo objetivo é consolidar os dados tratados da camada Silver para a modelagem analítica e consumo de negócio (como painéis de BI, planilhas e consultas SQL), ressaltando a importância de entender os conceitos por trás da codificação.

Revisão da arquitetura medalhão e diagnóstico inicial de dados: Guilherme Maciel revisou rapidamente as camadas Bronze (dados brutos da fonte), Silver

(dados deduplicados, padronizados e tipados) e Gold (regras de negócio e cálculo de indicadores). Utilizando a base de dados relacional de e-commerce (contendo clientes, pedidos, produtos, itens e pagamentos, onde o tempo de entrega e o status de prazo já foram calculados na Silver), Guilherme enfatizou a necessidade de realizar um diagnóstico da tabela e compreender rigorosamente o conceito de "grão" (o significado de cada linha em uma tabela) antes de iniciar a modelagem.

Análise de granularidade e o risco do problema de Fanout: Guilherme Maciel demonstrou, através de comandos Spark, a granularidade distinta entre a tabela de pedidos (uma linha por pedido, totalizando mais de 99.000 pedidos), itens por pedido (múltiplas linhas por item) e pagamentos por pedido. Guilherme alertou sobre o perigo do problema conhecido como "fanout", que ocorre ao realizar junções (joins) incorretas entre tabelas de grãos diferentes sem análise prévia, resultando na multiplicação indevida de linhas e na distorção de métricas financeiras críticas para a empresa (como inflar o faturamento de 16 milhões para 20 milhões).

Conceitos de modelagem analítica e definição de grão: Guilherme Maciel apresentou os conceitos fundamentais de data warehouse aplicados ao data lakehouse, diferenciando dimensões (contexto para filtragem e agrupamento, como cliente, produto e data), fatos (eventos mensuráveis do negócio, como itens vendidos ou pedidos fechados), medidas (métricas somáveis) e o grão (representação de uma linha na tabela fato). Guilherme explicou que a escolha de uma granularidade menor permite maior detalhamento, mas implica custos elevados de armazenamento e consultas mais lentas, exigindo um equilíbrio para atender adequadamente às necessidades da área de negócio.

Esquema Estrela versus Esquema Floco de Neve: Guilherme Maciel comparou o esquema estrela e o esquema floco de neve para a modelagem analítica na camada Gold. O esquema estrela utiliza dimensões desnormalizadas, aceitando redundância controlada para reduzir junções (joins) e otimizar a velocidade de consultas em painéis e dashboards, sendo a abordagem escolhida pela Viságio. Em contrapartida, o esquema floco de neve normaliza as dimensões em tabelas auxiliares (como separar a categoria de produtos e seus impostos), o que reduz redundâncias e garante maior integridade em atualizações, mas aumenta a complexidade e a quantidade de junções necessárias nas consultas.

Criação e importância da dimensão de data: Guilherme Maciel explicou a criação da dimensão de data, enfatizando a importância de um calendário contínuo para evitar lacunas em painéis de BI quando não há vendas registradas em determinados dias. A dimensão é enriquecida com atributos como trimestre, semestre, dia da semana e indicador de final de semana ou feriado. Além disso, Guilherme demonstrou o armazenamento de datas no formato numérico inteiro (ano, mês e dia, como `2026107`) para otimizar o desempenho de consultas SQL, ordenação e particionamento no Databricks. Utilizando funções do Spark como `sequence` e `explode` entre a primeira e a última data de compra, a dimensão gerou um total de 774 dias (634 com vendas e 140 dias preenchidos para manter a linearidade).

Tratamento de feriados na dimensão de data: Juan Perri questionou como contabilizar feriados específicos do Brasil na dimensão de data. Guilherme Maciel respondeu que o tratamento varia conforme a implementação, podendo utilizar bibliotecas específicas em Python ou criar tabelas auxiliares de "de-para" (muitas vezes estruturadas no Excel) contendo feriados nacionais, estaduais e municipais, prática adotada no projeto do próprio cliente.

Fonte única de verdade e modelagem da dimensão de cliente: Guilherme Maciel abordou a criação da dimensão de consumidor a partir da camada Silver, aplicando regras de negócio de CRM para segmentar a clientela com base no histórico de compras (sem compra, primeira compra, recorrente ou fiel). Rafael Tomaz complementou a discussão introduzindo o conceito de fonte única de verdade e a importância de compreender sistemas corporativos reais, como ERPs (sistemas principais para finanças, ativos e passivos) e CRMs, explicando que, embora dados possam estar replicados em diferentes lugares, a equipe de dados deve identificar qual fonte é a mais confiável para cada natureza de informação e jornada do cliente.

Implementação da dimensão de consumidor e consolidação de dados: Guilherme Maciel detalhou a implementação técnica no Databricks para gerar a dimensão de consumidor, unindo a tabela de pedidos e a de clientes por meio de um `inner join` e `left join`. O processo utilizou a contagem distinta de pedidos por cliente, além de capturar a menor e a maior data de compra através das funções de agregação `min` e `max`. A função `coalesce` foi aplicada para tratar valores nulos, atribuindo zero a quem não realizou pedidos, e uma estrutura de condições

(`case when`) definiu os segmentos de CRM. O script resultou em 99.441 linhas processadas e salvas no catálogo unificado.

Modelagem das Dimensões de Cliente e Produto: Guilherme Maciel apresentou a estruturação da dimensão de clientes (contendo ID do consumidor, cidade, estado, prefixo de CEP, histórico de pedidos e valores de primeira e segunda compra) e da dimensão de produtos. Para os produtos, Guilherme Maciel definiu regras de negócio herdadas do projeto anterior de Silvia, estipulando que medidas ausentes fossem preenchidas com zero via `fillna`, o peso zero indicasse produto sem informação (classificado como "desconhecido"), e a faixa de peso fosse categorizada em desconhecido (peso <= 0), leve (< 500), médio (500 a 5000) e pesado (> 5000), além do cálculo do volume em centímetros cúbicos (00:59:19).

Modelagem da Tabela Fato de Itens: Guilherme Maciel detalhou a criação da tabela Fato de itens, onde cada linha representa um item de pedido, consolidando chaves únicas e medidas agregadas de clientes, produtos e datas (01:01:30). Guilherme Maciel explicou que foram calculados o preço do item, o preço do frete e o preço total, com a filtragem de registros órfãos e salvamento no catálogo totalizando 112.000 itens, com o objetivo de fornecer uma tabela direta e consultas mais rápidas para a área de negócios (01:03:58).

Modelagem da Tabela de Pedidos e KPIs: Guilherme Maciel demonstrou a construção da tabela de pedidos agregados por linha, aplicando a função `max_by` para determinar a forma de pagamento principal com base no maior percentual, evitando a falta de determinismo da função `first` (01:05:19). Guilherme Maciel calculou os KPIs solicitados pela área de negócio, incluindo percentual de frete, SLA de entrega (no prazo, atrasado ou não aplicável) e valor de pedido alto (marcado como verdadeiro para pedidos acima de 500), concluindo com a validação do grão da tabela (01:06:28).

Uso da Função Display do Databricks para Análise de Dados: Guilherme Maciel demonstrou a funcionalidade `display` no Databricks, destacando seu uso prático para aplicar filtros rápidos no status do pedido (como faturado ou enviado) e gerar um perfil de dados (*data profiling*) por coluna, o que permitiu visualizar contagens de nulos, zeros, valores mínimos, máximos (como 14 itens máximos), mediana, média e percentis durante as validações de transformação (01:09:33).

Tipos de Views no Databricks: Guilherme Maciel apresentou os diferentes tipos de views disponíveis no Databricks, especificando a view temporária (*Temp View*, restrita à sessão do notebook), a view temporária global (*Global Temp View*, acessível no cluster até o reinício), a view persistente (salva no catálogo e recalculada a cada chamada) e a view materializada (*Materialized View*, que armazena resultados em cache para otimizar custos e desempenho, sendo muito utilizada em cenários de *streaming*) (01:11:50).

Diferença entre View e Datamart: Juan Perri questionou sobre a distinção conceitual entre uma view e um datamart, perguntando se a view seria uma cópia local de parte dos dados (01:13:51). Guilherme Maciel esclareceu que a view atua em um escopo acima do datamart, servindo para visualizar uma fração específica dos dados (como dados restritos a São Paulo para a equipe de produtos), o que facilita a análise pelas áreas de negócio e reduz os custos financeiros associados ao tempo de execução do cluster no Databricks (01:15:02).

Conceito de Views em Bancos de Dados Relacionais: Rafael Tomaz complementou a explicação sobre views comparando-as a um apelido (*alias*) para consultas SQL complexas que envolvem múltiplos *joins* entre tabelas, permitindo salvar a estrutura da consulta como um objeto no banco para reutilização recorrente sem precisar reescrever os scripts (01:17:28).

Criação de Visões Analíticas por Estado e Mês: Guilherme Maciel abordou a criação prática de views analíticas para a área de negócios, ressaltando limitações da edição gratuita do Databricks para *temp views* e *materialized views* (01:20:06). Guilherme Maciel criou a view `receita_estado_mes` agrupando a receita por estado do cliente e mês, considerando o segmento, ano-mês, quantidade de pedidos (excluindo os cancelados), somas de receita de produtos e frete, e o ticket médio (01:21:07).

Criação da View de SLA de Entrega: Guilherme Maciel demonstrou a criação de uma segunda view focada no SLA de entrega por estado e mês, utilizando operações condicionais para contar pedidos no prazo transformando strings em valores binários (1 ou zero) para posterior soma e cálculo percentual, além de incluir as médias de dias de entrega (01:23:49).

Uso do SQL Editor e Visualizações Gráficas no Databricks: Guilherme Maciel utilizou o Editor SQL do Databricks para executar consultas na view de receita e gerou rapidamente um gráfico de linhas no eixo X (ano-mês) e eixo Y (receita de produtos), destacando a utilidade dessa ferramenta para validar dados e apresentar resultados visuais para áreas de negócio sem a necessidade de construir dashboards complexos (01:25:47).

Comunicação de Dados e Contação de Histórias para Clientes: Juan Perri perguntou sobre como comunicar dados de forma clara para o cliente final com pouca noção técnica (01:28:02). Guilherme Maciel pontuou que as áreas de negócio frequentemente validam os dados comparando valores agregados conhecidos (como faturamento mensal) com o entregue pelo time técnico (01:29:13). Rafael Tomaz acrescentou que é fundamental compreender quem visualizará a informação, documentar premissas e fontes rigorosamente, estruturar a narrativa correta dos dados para apoiar decisões estratégicas e evitar manipulações visuais, recomendando a leitura do livro "Storytelling com Dados" (01:30:34).

Orquestração de Pipelines e Jobs no Databricks: Guilherme Maciel explicou a importância de ferramentas de orquestração (como Airflow e os *Jobs* nativos do Databricks) para automatizar execuções de ETL (Bronze, Silver, Gold) sem a necessidade de rodar notebooks manualmente (01:35:12). Guilherme Maciel detalhou a criação de jobs, a definição de tarefas (*tasks*) sequenciais para cada camada, o uso de condições de controle, alertas SQL e conexão com a ferramenta de inteligência artificial generativa do Databricks (01:36:20).

Configuração de Gatilhos e Dependências em Pipelines: Guilherme Maciel abordou as opções de gatilhos (*triggers*) para disparar pipelines no Databricks, incluindo execução agendada por horário (usando sintaxe *Cron*), atualização de tabela (*table update*), eventos de chegada de arquivos em pastas de *landing*, execução contínua para *streaming*, e atualização de modelos de inteligência artificial (01:39:58). Guilherme Maciel também demonstrou como definir dependências de execução entre tarefas anteriores e posteriores, bem como caminhos para tratamento de erros (01:43:45).

Uso de Parâmetros em Notebooks e Encerramento da Aula: Guilherme Maciel explicou a aplicação de parâmetros em notebooks para cenários específicos, como diferenciação de ambientes (desenvolvimento versus produção) ou filtragem por unidade federativa (*UF*, como São Paulo ou Rio Grande do Sul), permitindo executar consultas parametrizadas (01:44:50). Rafael Tomaz encerrou a sessão informando sobre a disponibilidade da gravação e dos materiais no portal, além de lembrar sobre a próxima aula de visualização em Power BI com Edu Osborne marcada para terça-feira (01:47:56).

Revise as anotações do Gemini para checar se estão corretas. Confira dicas e saiba como o Gemini faz anotações

*Como está a qualidade de **destas observações?** Responda a uma breve pesquisa para nos dar seu feedback, incluindo o quanto as observações foram úteis para o que você precisa.*